

Семинар №4 “Доклады, посвященные LLM Attacks and Resistance”.

Техническое и программное обеспечение семинара: компьютер с выходом в Интернет.

Оборудование в аудитории: экран и проектор, шнур HDMI.

Домашнее задание ПОСЛЕ семинара: нет

Вводная часть. 5 минут

ВОПРОСЫ ПО ЛЕКЦИИ ДЛЯ ЗАКРЕПЛЕНИЯ МАТЕРИАЛА

- Какие этапы обучения привели к созданию InstructGPT?
- Зачем нужен alignment и какие способы вы знаете?
- Как модель генерирует ответ? Какие виды семплирования вы знаете, для чего нужна температура?

СВЯЗЬ СЕМИНАРА И ЛЕКЦИИ

- Узнать, какие проблемы остаются даже после выравнивания (alignment) модели.

ЦЕЛЬ СЕМИНАРА

- Разобрать несколько ключевых работ в направлении LLM Attacks.

ПЛАН/ЗАДАЧИ ЗАНЯТИЯ:

- Последовательный разбор ключевых работ в направлении LLM Attacks
- 4 доклада по заданным ранее темам, на каждый доклад дается 15 минут выступления студента, а также 5 минут на вопросы со стороны семинариста/аудитории.

ПРОВЕРКА ДОМАШНЕГО ЗАДАНИЯ

Не ожидается, т.к. семинар докладный

НАПОЛНЕНИЕ СЕМИНАРА.

Практическая часть, 70 минут

Доклады студенты получили после 5 лекции “InstructGPT”. Их задачей было прочитать статьи и подготовить презентации с их разбором. Каждая презентация должна включать 1-2 слайда введения, где описывается какую задачу хотели решить авторы, основная

часть с разбором ключевой идеи, а также разбор экспериментов, которые подтверждают успешность атаки.

Каждому студенту дается **15 минут на доклад**, после не более **5 минут дискуссии**, где остальная группа может задать вопросы.

Преподаватель организывает дискуссию и следит за тем, чтобы она велась безопасно для участников (без критики) и эффективно для образовательного процесса.

- Разбор статьи "[Ignore Previous Prompt: Attack Techniques For Language Models](#)"
- Разбор статьи "[Prompt Injection attack against LLM-integrated Applications](#)"
- Разбор статьи "[Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection](#)"
- Разбор статьи "[Universal and Transferable Adversarial Attacks on Aligned Language Models](#)"

Заключительная часть, до 5 минут.

Преподаватель обязательно подводит итоги обсуждения докладов, выделяет сильные стороны. Можно студентов спросить какие моменты из семинара были:

- 1) новыми и наиболее интересными;
- 2) непонятными и хочется изучить их самостоятельно.

ВЫВОД И ПРАКТИЧЕСКАЯ ПОЛЬЗА.

- После данного семинара у студентов появляется понимание того, какие способы атак на модели существуют, и как от них защищаться.

ДОМАШНЕЕ ЗАДАНИЕ

Не предусмотрено

ПОЛЕЗНЫЕ МАТЕРИАЛЫ (не входит в тайминг).

- <https://arxiv.org/abs/2403.04786>
- <https://github.com/llm-attacks/llm-attacks>