

Семинар №5 “Доклады, посвященные Mixture of Experts”.

Техническое и программное обеспечение семинара: компьютер с выходом в Интернет.

Оборудование в аудитории: экран и проектор, шнур HDMI.

Домашнее задание ПОСЛЕ семинара: нет

Вводная часть. 5 минут

ВОПРОСЫ ПО ЛЕКЦИИ ДЛЯ ЗАКРЕПЛЕНИЯ МАТЕРИАЛА

- Что такое Transformer, из каких блоков состоит один слой трансформера? Как внутренне устроен Feed-Forward блок, какие размерности на входе и какие на выходе?
- Приведите примеры возможных модификаций Feed-Forward блока.
- Какие виды параллелизма обучения бывают? Чем Model отличается от Data параллелизма? На что ориентироваться при масштабировании модели и вычислительного кластера.

СВЯЗЬ СЕМИНАРА И ЛЕКЦИИ

- Закрепить на практике знание об архитектуре трансформера и его модификациях, а также возможных способах эффективно нарастить число параметров
- Познакомиться с еще одним способом модифицировать архитектуру, а также как это эффективно реализовать

ЦЕЛЬ СЕМИНАРА

- Разобрать несколько ключевых работ в направлении Mixture of Experts
- Разобрать теоретических аспекты таких моделей – дополнительные Loss-функции, использование разреженных матриц, влияние гиперпараметров на процесс обучения
- Разобрать практические аспекты таких моделей – что такое expert parallelism, как должна осуществляться тренировка MoE с точки зрения кластера и как эффективно использовать матричные умножения

ПЛАН/ЗАДАЧИ ЗАНЯТИЯ:

- Последовательный разбор ключевых работ в направлении Mixture of Experts
- 4 доклада по заданным ранее темам, на каждый доклад дается 15 минут выступления студента, а также 5 минут на вопросы со стороны семинариста/аудитории.

ПРОВЕРКА ДОМАШНЕГО ЗАДАНИЯ

Не ожидается, т.к. семинар докладный

НАПОЛНЕНИЕ СЕМИНАРА.

Практическая часть **70 минут.**

Доклады студенты получили после третьей лекции “Transformers and beyond”. Их задачей было прочитать статьи и подготовить презентации с их разбором. Каждая презентация должна включать 1-2 слайда введения, где описывается какую задачу хотели решить авторы, основная часть с разбором архитектурных и технических нововведений в статье, а также отличие от разобранных моделей на лекции, а также разбор экспериментов, которые подтверждают пользу введённых модификаций.

Каждому студенту дается 15 минут на доклад, после не более 5 минут дискуссии, где остальная группа может задать вопросы.

Преподаватель организывает дискуссию и следит за тем, чтобы она велась безопасно для участников (без критики) и эффективно для образовательного процесса.

- Разбор статьи “[Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer](#)”
- Разбор статьи “[GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding](#)”
- Разбор статьи “[Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity](#)”
- Разбор статьи “[MegaBlocks: Efficient Sparse Training with Mixture-of-Experts](#)” и “[Mixtral of Experts](#)”

Заключительная часть, до 5 минут.

Преподаватель обязательно подводит итоги обсуждения докладов, выделяет сильные стороны. Можно студентов спросить какие моменты из семинара были:

- 1) новыми и наиболее интересными;
- 2) непонятными и хочется изучить их самостоятельно.

ВЫВОД И ПРАКТИЧЕСКАЯ ПОЛЬЗА.

- После данного семинара у студентов появляется понимание того, что такое Mixture of Experts, а также процесс эффективного обучения таких моделей.

ДОМАШНЕЕ ЗАДАНИЕ

Не предусмотрено

ПОЛЕЗНЫЕ МАТЕРИАЛЫ (не входит в тайминг).

- <https://huggingface.co/blog/moe>
- https://vk.com/lab?w=wall-187376020_354
- <https://arxiv.org/abs/2407.06204>